

POLITECHNIKA POZNAŃSKA

WYDZIAŁ INFORMATYKI



PRACA MAGISTERSKA

System bezpieczeństwa i zarządzania domem w IoT

Autor:

inż.

Mateusz Szymkowiak

Promotor:

dr inż.

Michał Melosik

20 sierpnia 2018

Streszczenie

W pracy zaprezentowano system bezpieczeństwa i zarządzania domem w Internet of Things. Główny obiekt badań, na którym skupiono się w tej pracy są systemy detekcji oraz rozpoznawania twarzy. Na potrzeby tej pracy utworzono aplikację internetową umożliwiającą sprawne testowanie wybranych algorytmów, sieci neuronowych oraz usług pozwalających na analizę obrazu. Z powodu niewystarczającej mocy obliczeniowej platformy Raspberry Pi, przetestowano środowiska Azure oraz AWS pozwalające na uruchomienie aplikacji w chmurze.

Abstract

english

Spis treści

1	Wstęp TODO	6
2	Cel i zakres prac	7
3	Wstęp teoretyczny	8
3.1	Technologie	8
3.2	Raspberry Pi	10
3.3	Open Cv	11
3.4	Azure	14
3.5	AWS	14
4	System zarządzania metodami rozpoznawania twarzy	15
4.1	Budowa aplikacji	15
4.2	Konfiguracje uruchomieniowe TODO	16
5	Aplikacja internetowa	17
5.1	Technologie	18
5.2	Detections	19
5.3	People	21
5.4	Neural Networks	22
5.5	Recognitions	23
5.6	Readings TODO	24
6	Aplikacja konsolowa	25
6.1	Technologie	25
6.2	Proces wykrywania twarzy	26
6.3	Proces trenowania sieci neuronowych	28
6.4	Proces rozpoznawania twarzy	30
7	Ocena skuteczności działania ... (wybranych metod) TODO	34
7.1	Wykrywanie twarzy - różne przykłady	34
7.2	Trenowanie- czas trwania itd	34

7.3	Rozpoznawanie- skuteczność, porównanie wyników	34
7.4	Ocena przydatności wybranych usług itd w IoT	34
8	Podsumowanie	35
	Bibliografia	35
	Dodatki	37
	Spis rysunków	38
	Spis tablic	40

Rozdział 1

Wstęp **TODO**

Internet rzeczy (Internet of Things -IoT) to koncepcja przedstawiająca sieć urządzeń fizycznych połączonych inteligentną siecią KNX lub internetową, komunikujących się między sobą i wymieniających dane. Podstawowym celem IoT jest stworzenie inteligentnych przestrzeni- miast, budynków lub systemów związanych z życiem codziennym. Jednym z zastosowań takich systemów są inteligentne domy (smart homes), wykorzystujące czujniki oraz akulatory do zarządzania domem.

Na potrzeby tej pracy opracowano system bezpieczeństwa oparty o system detekcji i rozpoznawania twarzy na obrazie.

W rozdziale drugim pt. „Cel i zakres pracy” przedstawiono główne założenia projektu oraz zakres prac autora.

Rozdział 2

Cel i zakres prac

Celem pracy było stworzenie systemu bezpieczeństwa i zarządzania domem w IoT. Głównymi założeniami było opracowanie systemu pozwalającego na porównanie wybranych metod i usług pozwalających na analizę obrazu oraz kontrolę stanu czujników podłączonych do systemu. IoT jest bardzo prężnie rozwijającą się ideą, dlatego postanowiono porównać wybrane technologie i usługi ułatwiające zarządzanie oraz integrację z takimi aplikacjami.

Jako platformę sprzętową wybrano bardzo popularne w zastosowaniach IoT urządzenie Raspberry Pi 3. Z powodu jego ograniczonych zasobów obliczeniowych zintegrowano chmurowe usługi Azure oraz AWS. Zakres pracy obejmuje następujące zagadnienia:


- dobór odpowiedniej platformy sprzętowej oraz oprogramowania,
- porównanie działania wybranych algorytmów detekcji oraz rozpoznawania twarzy,
- wybór i porównanie wybranych technologii umożliwiających integrację z systemami IoT,
- wykrywanie zdarzeń rejestrowanych przez wybrane czujniki,
- opracowanie systemu przesyłania powiadomień, **czy mógłbym się tego pozbyć? komentarz w tym rozdziale- 'Po wcześniejszej konsultacji z promotorem postanowiono zrezygnować z zadania ' i skupieniu się na badaniu działania algorytmów rozpoznawania twarzy**
- ocena przydatności wybranych usług w zastosowaniu dla systemu bezpieczeństwa domu w IoT.

Rozdział 3

Wstęp teoretyczny

3.1 Technologie

3.1.1 Wzorzec projektowy MVC



Rysunek 3.1: Schemat klasycznego wzorca MVC

Strona internetowa powstała na bazie bardzo popularnego wśród programistów wzorca projektowego MVC. Założenia wzorca Model-Widok-Kontroler są bardzo proste, ich składowymi są:

- Model- reprezentuje logikę biznesową. Tutaj znajdują się wszelkie obiekty, które służą do wykonywania zaimplementowanej funkcjonalności danej aplikacji,
- Widok- jest warstwą prezentacji. Odpowiada za prezentację logiki biznesowej (Modelu) użytkownikowi w przystępny sposób,
- Kontroler- obsługuje żądania użytkownika. Odebrane zadania oddelegowuje do odpowiednich modeli.

3.1.2 Single Page Application

Single Page Application (SPA) to aplikacja lub strona internetowa, która w całości wczytuje się za jednym razem. Cały potrzebny do działania strony kod (HTML, CSS, JavaScript) przesyłany jest na początku lub dodawany dynamicznie w kawałkach, zwykle w odpowiedzi na interakcje generowane przez użytkownika. Sposób działania takiej aplikacji jest zbliżony do odczuć towarzyszących korzystaniu z aplikacji desktopowej lub mobilnej.

3.1.3 Chmura obliczeniowa



Rysunek 3.2: Obliczenia chmurowe

Chmura obliczeniowa jest określeniem oznaczającym model przetwarzania danych oparty na użytkowaniu usług dostarczonych przez usługodawcę. Użytkownik nie musi opłacać licencji, a płaci jedynie za użytkowanie danej usługi. W przypadku takich usług najpopularniejszym sposobem naliczania kosztów jest opłata od czasu użytkowania usługi. DO najpopularniejszych udostępnianych usług należą:

- bazy danych,
- maszyny wirtualne,
- serwery,
- hosting dla aplikacji webowych.

Przedstawicielami usługodawców udostępniających szeroki zakres usług, które zostały wykorzystane podczas tworzenia tej pracy magisterskiej jest Azure od Microsoft oraz AWS stworzony przez Amazon. Usługi obu podmiotów, które mogą być przydatne podczas tworzenia rozwiązania zostały szerzej opisane w podpunkcie 3.4 i 3.5.

3.1.4 1-Wire

One Wire to systemowa magistrala komunikacji elektronicznej pomiędzy urządzeniami, zapewniająca przesyłanie danych oraz zasilanie urządzenia przez pojedynczy kabel. Proces ten jest możliwy dzięki stopniowemu ładowaniu kondensatora znajdującego się w odbiorniku, a następnie wykorzystanie zgromadzonej energii do zasilenia urządzenia. Do magistrali może zostać podłączonych wiele urządzeń. Każdemu z nich przydzielany jest indywidualny adres 64-bitowy. Komunikację z urządzeniami inicjuje master, w tym przypadku Raspberry Pi. Przedstawiony protokół jest bardzo podobny do I2C, ale ze względu na wykorzystanie jedynie jednej linii danych, charakteryzuje się niższą prędkością przesyłania. Układ zazwyczaj zasilany jest napięciem o wartości 5V i służy do komunikacji pomiędzy niewielkimi urządzeniami, takimi jak np. termometr cyfrowy i mikrokontroler.


3.2 Raspberry Pi

Raspberry Pi jest platformą komputerową stworzoną przez Raspberry Pi Foundation, na którą składa się pojedynczy obwód drukowany. Pierwsza wersja tego urządzenia została zaprezentowana w 2012 roku. Na potrzeby tej pracy wykorzystano nowszą wersję urządzenia w wersji 3 B, którą została wyposażona w 4 rdzeniowy procesor i 1 GB pamięci RAM. Raspberry pozwala na podłączenie wielu urządzeń peryferyjnych za pomocą 4 portów USB lub 40 pinów GPIO. Dodatkowe złącze pozwala na podłączenie dedykowanej kamery. Dzięki znacznej ilości portów GPIO istnieje możliwość komunikacji cyfrowej z sensorami. Budowa urządzenia nie pozwala na podłączenie czujników analogowych.



Rysunek 3.3: Raspberry Pi 3 B

3.2.1 Czujnik DHT 11



Rysunek 3.4: Czujnik DHT11


Czujnik temperatury i wilgotności powietrza DHT11 jest bardzo popularnym czujnikiem z interfejsem cyfrowym. Do komunikacji wykorzystuje on protokół 1-wire opisany w rozdziale 3.1.4.

Tablica 3.1: Parametry czujnika

Parametr	Wartość
Napięcie zasilania	3,3V do 5,5V
Średni pobór prądu	0,2 mA
Zakres pomiaru temperatury	od - 20°C do +50°C
Zakres pomiaru wilgotności	od 5% do 95% wilgotności względnej

3.2.2 Raspberry Pi Camera HD

Raspberry Pi Camera HD jest dedykowaną kamerą przeznaczoną tylko i wyłącznie do urządzenia Raspberry Pi w wersji 3, 2 oraz B+. Szybszy transfer danych niż przez port USB zapewnia dedykowane złącze minikomputera (w formie taśmy na zdjęciu 3.5). Kamera posiada matrycę o rozdzielczości 8 Mpx, wspiera tryb HD 1090p, 720p oraz 640 x 480. Moduł umożliwia wykonywanie zdjęć w rozdzielczości nawet 3280 x 2464 px. Wymagane sterowniki są preinstalowane na kompatybilnych urządzeniach.



Rysunek 3.5: Raspberry Pi Camera Hd

3.3 Open Cv

OpenCv (Open Source Computer Vision Library) jest open sourcową biblioteką napisaną w języku C. Udostępniono liczne interfejsy biblioteki pozwalające na pracę z nią między innymi w języku C++ i Python. Biblioteka wspiera systemy operacyjne Linux oraz Windows. Biblioteka

została ukierunkowana na przetwarzanie obrazu w czasie rzeczywistym. W licznie udostępnionych funkcjach można znaleźć moduły pozwalające na detekcję i rozpoznawanie twarzy na obrazie, które zostały szerzej opisane w kolejnym punkcie.

3.3.1 Detekcja twarzy

Głównym wykrywaczem twarzy wykorzystywanym przez OpenCv jest kaskadowy klasyfikator Haar’a ale poza nim istnieją również inne metody. Jedną z nich jest wykorzystanie głębokiej sieci neuronowej.

Klasyfikator kaskad Haar’a

Detekcja obiektów klasyfikatorem kaskad Haar’a została oparta o metodę Paul’a Viola i Michael’a Jones’a – w skrócie Viola-Jones.

Algorytm Viola-Jones

Jest to jeden z pierwszych algorytmów pozwalających na osiągnięcie zadowalających wyników w detekcji obiektów na obrazie. Został on zaproponowany w 2001 roku i został przemysłany z głównym przeznaczeniem dla detekcji twarzy. Na kluczowe koncepcje tej metody składają się:

- wyszukiwanie cech Haar’a,
- integralność obrazu,
- metoda uczenia AdaBoost (podstawowy algorytm do boostingu, metoda dzięki której z dużej liczby słabych klasyfikatorów można otrzymać jeden lepszy)

Cechy Haar’a

Cechy wykorzystywane w metodzie Viola-Jones opierają się na falkach Haara. Falki Haara są to sekwencje przeskalowanych kwadrato-podobnych funkcji, które razem tworzą falę(falopodobną oscylację), podstawę z której można zbudować kwadrat. W dwóch wymiarach, fala kwadratu jest parą przylegających do siebie prostokątów, gdzie jeden jest jaśniejszy, a drugi ciemniejszy.




Rysunek 3.6: Szablony cech Haar’a

Wartość każdej cechy jest obliczana jako różnica sumy poziomów szarości pikseli pokrywanych przez biały oraz czarny prostokąt oraz sumy poziomów szarości pikseli pokrywanych przez

czarny prostokąt. Składniki tej różnicy posiadają wagi odwrotnie proporcjonalne do rozmiarów, dzięki czemu różnice wielkości dwóch obszarów są kompensowane.

Głęboka sieć neuronowa

Pojęciem uczenia maszynowego określa się dziedzinę nauk związanych ze sztuczną inteligencją, zajmującą się badaniem algorytmów i systemów, które usprawniają swoje działanie wraz ze zdobywaniem nowej wiedzy lub też doświadczeniem. Wiedzą określamy dane uczące, które zostały wykorzystane do nauki. System może zostać usprawniony poprzez zwiększenie wiedzy systemu, które powinno pozwolić na usprawnienie procesu rozwiązywania podstawowych problemów.



Rysunek 3.7: Budowa głębokiej sieci neuronowej

Algorytmy głębokiego uczenia maszynowego są jednymi z najbardziej zaawansowanych. Zbudowane są one w sposób przypominający biologiczne sieci neuronowe. Głęboka sieć neuronowa składa się z neuronów rozmieszczonych na warstwach. Wiele warstw jest powodem dla którego taki rodzaj algorytmu określa się mianem głębokiego. Przykładowa budowa głębokiej sieci neuronowej została przedstawiona na rysunku 3.7.

Każdy z takich “sztucznych neuronów” jest tak naprawdę informacją, która jest przesyłana dalej do następnych neuronów i ich warstw. Poszczególne warstwy “uczą” się przetwarzać kolejne cechy obiektów/obrazów/dźwięków itp., dzięki czemu są w stanie odtwarzać całe obiekty w bardzo rzeczywisty sposób.

3.3.2 Rozpoznawanie twarzy **TODO**

Eigenfaces

The PCA method finds the directions with the greatest variance in the data, called principal components.

Fisherfaces

Local Binary Patterns Histograms

3.4 Azure

3.4.1 App Services

3.4.2 Bazy danych SQL

3.4.3 Maszyny wirtualne

3.4.4 Azure Cognitive Services

Cognitive Services jest częścią platformy Azure stworzonej przez Microsoft. Usługa jest standardowo płatna, ale w przypadku użytku na potrzeby studenckie przyznawany jest darmowy dostęp na ograniczony czas. Cognitive Services zajmuje się rozwiązywaniem problemów biznesowych dzięki sztucznej inteligencji. Do dostępnych modułów między innymi należą:

- obraz- algorytmy przetwarzania obrazów umożliwiające inteligentne identyfikowanie, podpisywanie i moderowanie grafik,
- mowa- konwertowanie wypowiedzi audio na tekst, weryfikacja głosowa,
- język- przetwarzanie języka naturalnego.

Na cele tego projektu wykorzystano moduł dotyczący przetwarzania obrazu, a dokładniej wykrywanie i rozpoznawanie twarzy w nim dostępne. Producent zadbał o prostą możliwość integracji z większością popularnych języków programistycznych poprzez udostępnienie paczek deweloperskich. W przypadku braku SDK dla wybranego języka istnieje możliwość skorzystania z udostępnionego REST Api. Na stronie producenta można znaleźć obszerną dokumentację oraz tutoriale.

3.5 AWS

3.5.1 Elastic Beanstalk

3.5.2 EC2

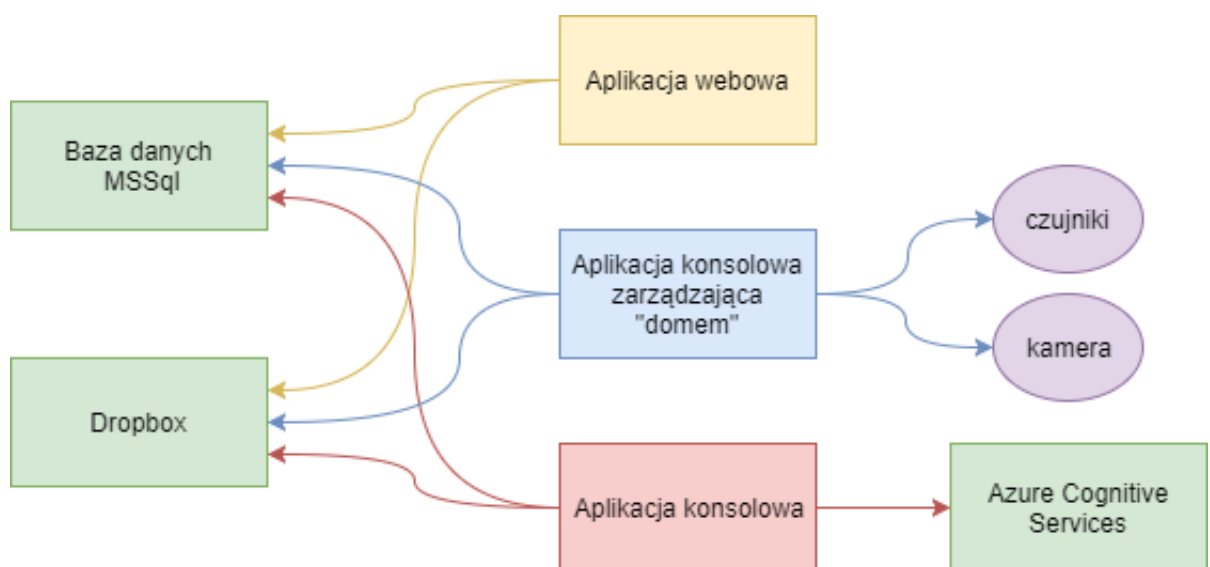
3.5.3 RDS

3.5.4 Rekognition

Rozdział 4

System zarządzania metodami rozpoznawania twarzy

4.1 Budowa aplikacji



Rysunek 4.1: Budowa systemu zarządzania domem

Aplikację powstałą na potrzeby tej pracy można podzielić na 3 moduły, które zostały przedstawione na rysunku 4.1, a składają się na nie :

- Aplikacja webowa- interfejs pozwalający na zlecanie nowych zadań aplikacji konsolowej, odczyt wyników przesłanych przez obie aplikacje konsolowe,
- Aplikacja konsolowa- przetwarza zadania detekcji oraz rozpoznawania twarzy zlecone za pomocą aplikacji webowej,

- Aplikacja konsolowa zarządzająca domem- przekazuje cyklicznie odczytywane dane z czujników

We wczesnej fazie projektu istniała jedna aplikacja konsolowa, ale ze względu na skomplikowość programu przetwarzającego zadania, została ona rozdzielona na aplikację, która musi być uruchamiana na Raspberry Pi (program zarządzający domem) oraz drugą, którą można uruchomić w dowolnym innym środowisku. Na usługi pomocnicze wykorzystane w projekcie składają się

- baza danych MSSql- przechowywanie danych o dodanych zadaniach, wynikach, nauczonych sieciach neuronowych oraz osobach,
- Dropbox- przechowywanie większych plików- obrazów oraz nauczonych modeli sieci,
- Azure Cognitive Services- Web Api usługi przetwarzającej obrazy opisanej w rozdziale ??.

4.2 Konfiguracje uruchomieniowe **TODO**

W celu zmaksymalizowania wydajności każdego z modułów, podjęto decyzję o uruchomieniu każdego z nich w odrębnym środowisku. System został uruchomiony w dwóch konfiguracjach. Niezależnie dla konfiguracji niezmienny pozostał moduł aplikacji konsolowej zarządzającej "domem", który ze względu na wymaganie fizycznego dostępu do urządzeń podłączonych do Raspberry Pi, zawsze był uruchamiany w tym środowisku. Pierwsza z konfiguracji została oparta o środowisko chmurowe Azure, a druga AWS.

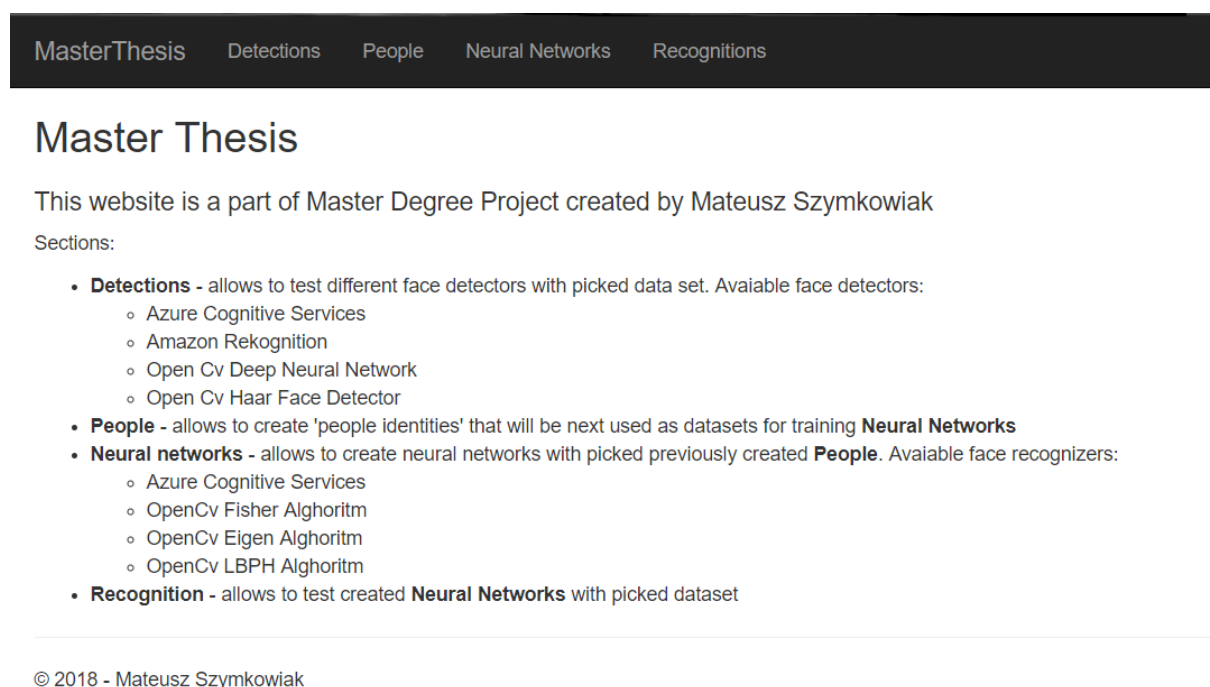
4.2.1 Konfiguracja 1- Azure

4.2.2 Konfiguracja 2- AWS

Rozdział 5

Aplikacja internetowa

Aplikacja webowa jest jedyną częścią systemu, do której użytkownik może mieć bezpośredni dostęp. Strona powstała w celu maksymalnego uproszczenia procesu badania kolejnych algorytmów i usług, które różniły się sposobem podawania danych wejściowych, sposobem uczenia oraz formatem zwracanych odpowiedzi. Do pozostałych zalet takiego rozwiązania należy ułatwienie przechowywania danych, poprzez umieszczenie ich we wspólnym miejscu co pomaga, w późniejszej interpretacji wyników.



Rysunek 5.1: Wygląd strony głównej

Zgodnie z interfejsem przedstawionym na rysunku 5.1, strona została podzielona na 5 głównych sekcji:

- Detections- detekcje,
- People- ludzie,
- Neural Networks- sieci neuronowe,
- Recognition- rozpoznawanie,
- Sensor Readings- odczyty sensorów.

5.1 Technologie

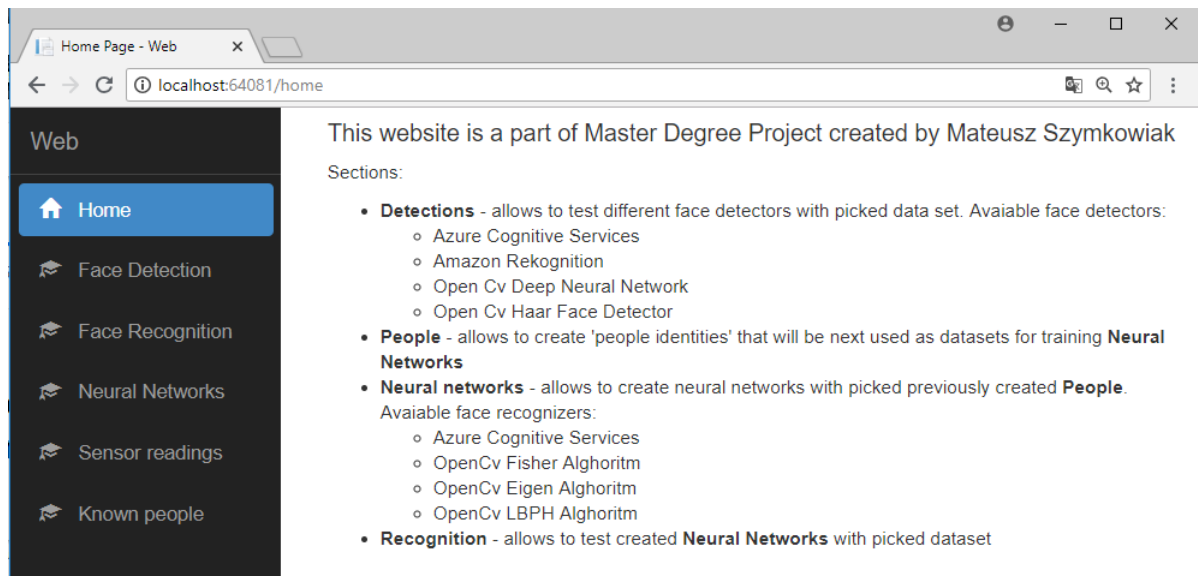
Aplikacja webowa powstała w najnowszej kompilacji .NET Core 2, będącej międzyplatformową strukturą open source o wysokiej wydajności służącą do tworzenia nowoczesnych aplikacji internetowych opartych na usługach chmurowych. Logika biznesowa aplikacji została zaprogramowana w języku C#. Warstwa widoku powstała w dwóch dostępnych rozwiązaniach, nieznacznie różniących się wyglądem, ale znacznie odbiegających od siebie sposobem działania. Przed omówieniem poszczególnych rozwiązań przedstawiono, krótkie definicje wykorzystanego wzorca projektowego MVC oraz technologii SPA.

5.1.1 Rozwiązanie 1- Razor Pages

Pierwsza wersja została oparta o strony tworzone w technologii Razor Pages opartej o składnię Razor oraz podstawowe technologie webowe: HTML i CSS. Taki sposób tworzenia warstwy prezentacji jest zalecany dla aplikacji .NET Core, ponieważ pozwala zminimalizować ilość pracy wymaganej na jej utworzenie oraz zapewnia bardzo prosty proces wdrożenia. Aplikacja utworzona z pomocą Razor'a została zaprezentowana na rysunku 5.1.

5.1.2 Rozwiązanie 2- Angular 4





Druga wersja widoku aplikacji oferuje dostęp do tych samych możliwości co pierwsze rozwiązanie, ale powstała przy pomocy frameworka webowego- Angular 4. Strona główna widoczna jest na rysunku 5.2. Angular jest open sourcowym frameworkiem używanym do tworzenia aplikacji SPA (Single Page Application), napisany w języku TypeScript i wspierany oraz rozwijany przez Google.



Rysunek 5.2: Strona główna widoku utworzonym w Angular 4

5.2 Detections

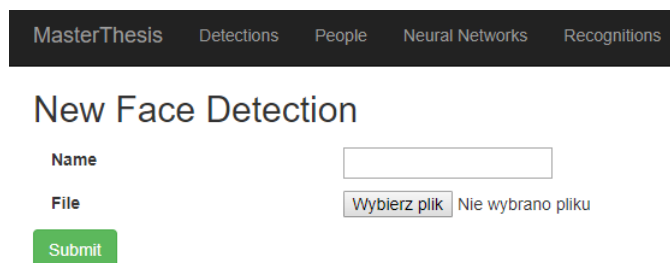
Detections jest stroną odpowiedzialną za wykrywanie twarzy na obrazach przesłanych do systemu. Na głównej stronie możemy zobaczyć wszystkie zlecone detekcje, zarówno nowe jak i już zakończone.

MasterThesis						
Detections						
New						
Id	Name	Input	Status	Creation Time	Completion Time	
4	test4		Completed	8/12/2018 7:52:43 AM	8/12/2018 7:57:44 AM	Show
3	test3		Completed	8/12/2018 7:02:45 AM	8/12/2018 7:07:47 AM	Show
2	test2		Completed	8/12/2018 6:53:28 AM	8/12/2018 6:57:51 AM	Show
1	test 1		Completed	8/7/2018 5:17:38 PM	8/7/2018 5:47:46 PM	Show

Rysunek 5.3: Widok detekcji twarzy

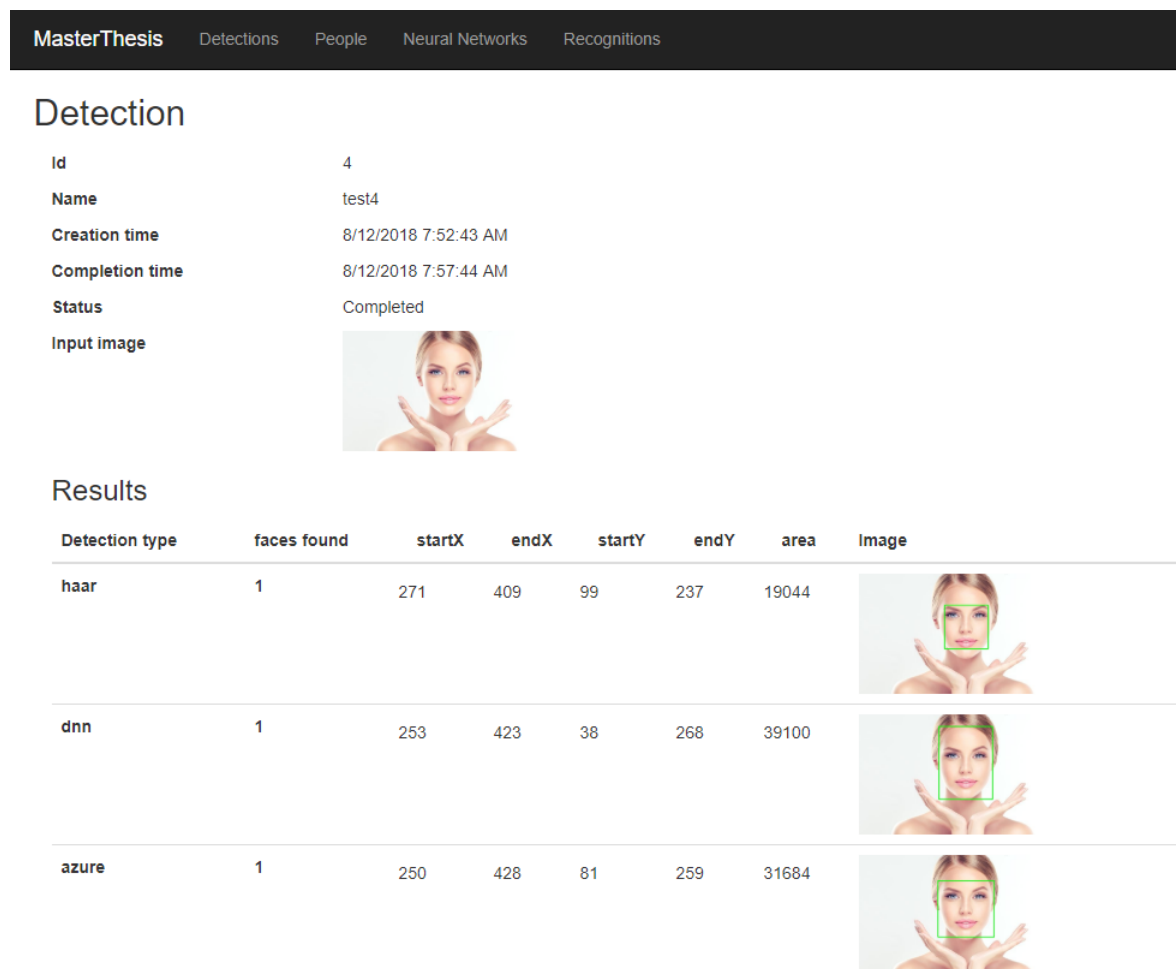
Przycisk 'New' widoczny na 5.3 pozwala na stworzenie nowego zadania wykrycia twarzy na obrazie, które zostanie przetworzone przez moduł aplikacji konsolowej. Na formularzu z rysunku

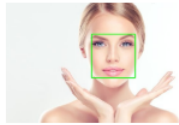


5.4 należy podać nazwę zadania oraz za pomocą przycisku 'Wybierz plik' wybrać obraz w formacie png,jpg lub jpeg znajdujący się na dysku użytkownika.



Rysunek 5.4: Tworzenie nowej detekcji

Użycie przycisku 'Show' widocznego przy każdym zadaniu detekcji na rysunku 5.3, pozwoli na wyświetlenie szczegółów związanych z requestem, w tym wyników jeśli zadanie zostało zakończone.



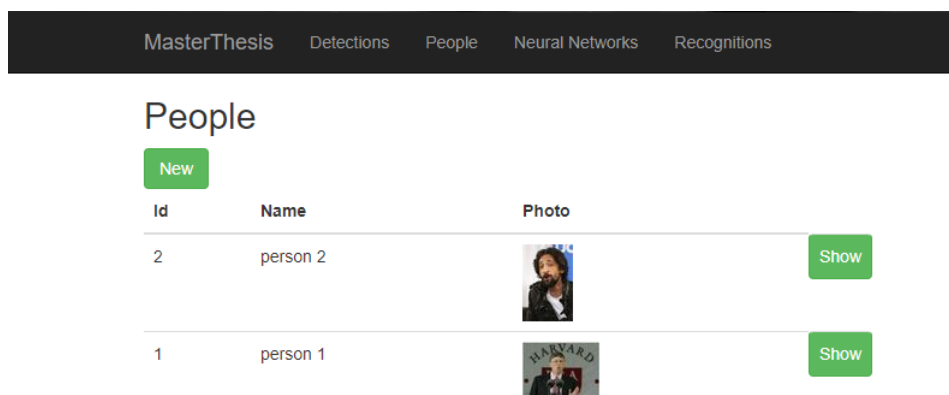
Detection type	faces found	startX	endX	startY	endY	area	Image
haar	1	271	409	99	237	19044	
dnn	1	253	423	38	268	39100	
azure	1	250	428	81	259	31684	

Rysunek 5.5: Widok zakończonej detekcji

Strona ze zdjęcia 5.5 pozwala sprawdzić datę utworzenia oraz zakończenia zadania, obraz wejściowy, szczegółowe informacje o obszarze zidentyfikowanym jako twarz oraz sposobie jej wykrycia.


5.3 People

Strona 'People' służy do tworzenia nowych znanych tożsamości, które później mogą zostać wykorzystane jako dane uczące podczas trenowania sieci neuronowych. Do każdej osoby musi zostać przypisany zasób minimum 2 zdjęć. W przypadku braku możliwości wykrycia twarzy na zdjęciu, zostanie ono zignorowane podczas procesu nauczania.



Rysunek 5.6: Lista utworzonych ludzi


Nowa osoba może zostać utworzona w podobny sposób jak request detekcji twarzy. Jediną różnicą jest wymóg wyboru kilku obrazów.



Rysunek 5.7: Widok osoby

Utworzona osoba nie może być modyfikowana. Pierwsze załadowanie widoku osoby może trwać wydłużony czas z powodu procesu generowania linków do plików magazynowanych w usłudze Dropbox.

5.4 Neural Networks




The screenshot shows the 'Neural Networks' page with a 'New' button and a table of existing groups. The table has columns for Id, Name, Trained people count, Number of files, Status, Creation Time, and Completion Time. Each row has a 'Show' button.

Id	Name	Trained people count	Number of files	Status	Creation Time	Completion Time	
8	test	2	4	Completed	8/12/2018 6:46:36 PM	8/12/2018 8:47:43 PM	Show
7	test	2	3	Completed	8/12/2018 6:44:13 PM	8/12/2018 8:46:13 PM	Show
6	test next	2	3	Completed	8/12/2018 6:40:16 PM	8/12/2018 8:43:51 PM	Show

Rysunek 5.8: Strona przedstawiająca istniejące grupy usług rozpoznawania tożsamości

W zakładce 'Neural Networks' użytkownik ma możliwość stworzenia grupy wybranych usług i sieci neuronowych, które zostaną nauczone rozpoznawać tożsamości utworzone w zakładce 'People'.



The screenshot shows the 'New Neural Network' form. It includes a 'Name' field with the value 'trzy osoby', a 'People included in neural network training' section with a table of people to include, and a 'Submit' button.

Include?	Id	Name
<input checked="" type="checkbox"/>	1	person 1
<input type="checkbox"/>	2	person 2
<input checked="" type="checkbox"/>	3	liv tyler

Rysunek 5.9: Tworzenie nowej grupy sieci neuronowych

Każda istniejąca osoba zostanie wyświetlona jako checkbox, który należy zaznaczyć jeśli użytkownik chce by dana osoba została wykorzystana podczas procesu trenowania. Należy wybrać minimum 2 osoby, w przypadku wyboru mniejszej ilości osób, użytkownik zostanie poinformowany o tej konieczności.

Widok ukazany na rysunku 5.8 pozwala sprawdzić ile osób zostało użytych w procesie nauki oraz ile sieci neuronowych zostało utworzonych. Wyświetlenie jednej z grup pozwoli na uzyska-

nie bardziej szczegółowych informacji na temat wykorzystanych osób i utworzonych sieci, patrz rysunek 5.10.

Neural Network

Id	8
Name	test
Completion time	8/12/2018 8:47:43 PM

People data used for training

Id	Name	
1	person 1	Show
2	person 2	Show




Trained files

Id	Name	Type
20	8_Eigen.xml	Eigen
21	8_Fisher.xml	Fisher
22	8_LBPH.xml	LBPH
23	8	AzureLargeGroup

Rysunek 5.10: Szczegółowe informacje o grupie sieci neuronowych

5.5 Recognitions

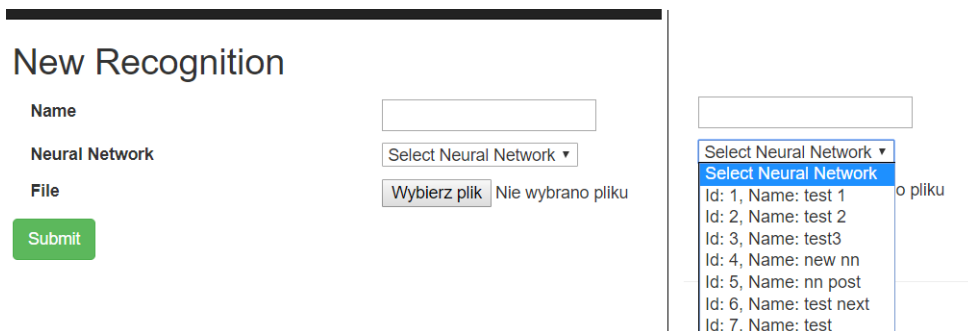
W sekcji 'Recognitions' użytkownik ma możliwość wykorzystać wcześniej utworzone zbiory sieci neuronowych w celu identyfikacji tożsamości na zdjęciu przedstawiającym pojedynczą osobę.

Recognitions					
New					
Id	Name	Input	Status	Creation Time	Completion Time
12	test liv		New	8/12/2018 8:33:19 PM	Show
11	test		Completed	8/12/2018 8:30:42 PM	8/12/2018 10:31:12 PM Show
10	test		Error	8/12/2018 8:11:42 PM	8/12/2018 10:29:15 PM Show

Rysunek 5.11: Lista zadań identyfikacji osoby

Podobnie jak na pozostałych stronach, podczas tworzenia nowego zadania użytkownik będzie musiał uzupełnić prosty formularz. W formularzu przedstawionym na rysunku 5.12 należy

załączyć jedno zdjęcie oraz wybrać grupę sieci neuronowych, która ma zostać wykorzystana do identyfikacji tożsamości osoby.



New Recognition

Name:

Neural Network:


File: Nie wybrano pliku

Select Neural Network

- Id: 1, Name: test 1
- Id: 2, Name: test 2
- Id: 3, Name: test3
- Id: 4, Name: new nn
- Id: 5, Name: nn post
- Id: 6, Name: test next
- Id: 7, Name: test

Rysunek 5.12: Formularz tworzenia zadania identyfikacji

Po zakończonym procesie identyfikacji opisanym w kolejnym podrozdziale, użytkownik może wyświetlić wynik uzyskany przez każdą sieć dostępną w grupie. Przykładowy rezultat widoczny jest na zdjęciu 5.13.



Recognition


Id: 13

Name: test

Creation time: 8/12/2018 8:48:14 PM

Completion time: 8/12/2018 10:48:48 PM

Status: Completed

Input image: 

Results

Recognised Identity	Confidence	Neural Network Name	Neural Network Type	Comments
3	0	10_Eigen.xml	Eigen	
3	0	10_Fisher.xml	Fisher	
3	0	10_LBPH.xml	LBPH	
3	1	10	AzureLargeGroup	

Rysunek 5.13: Zakończony request identyfikacji


5.6 Readings **TODO**

zrobić zdjęcia i opisać

Rozdział 6

Aplikacja konsolowa

Aplikacja konsolowa powstała w celu przetwarzania czasochłonnych zadań w tle, tak by użytkownik aplikacji webowej nie doświadczał długich czasów ładowania oraz ewentualnych błędów podczas przerwania sesji lub połączenia internetowego ze stroną. Aplikacja konsolowa uruchamiana jest co 5 minut i przetwarza zadania trzech typów w kolejności widocznej na rysunku 6.1. Poszczególne procesy zostały szerzej opisane w kolejnych podrozdziałach.



Rysunek 6.1: Proces działania aplikacji konsolowej

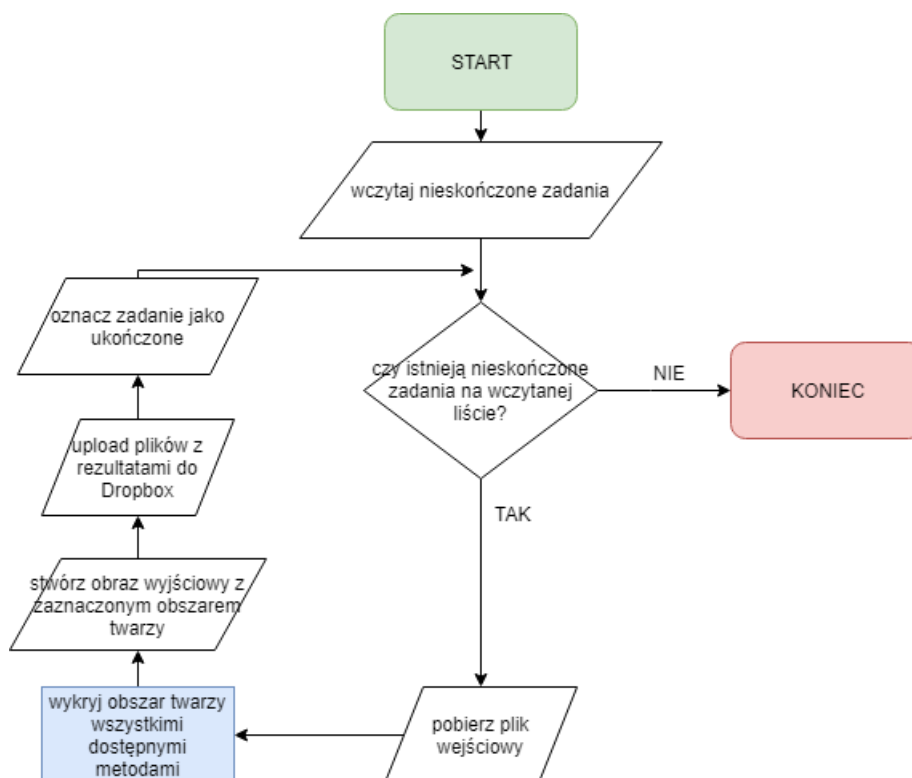
6.1 Technologie

Aplikacja konsolowa powstała w języku programowania Python w wersji trzeciej. W początkowej fazie projektu za wyborem tego języka przemawiała wieloplatformowość, możliwości wprowadzania szybkich zmian w kodzie i brak potrzeby go kompilowania. C#, który został wybrany do stworzenia aplikacji webowej okazał się nie przystosowany do uruchomienia na plat-

formie Raspberry Pi z powodu braku dostępnego .NET Core SDK na procesory ARM oraz wymaganiu znacznie większej ilości zasobów niż Python. Ostatecznie aplikacja konsolowa została przeniesiona na zewnętrzny serwer, ale popularność Pythona pozwoliła na szybką integrację z usługami firm trzecich, dzięki przygotowanym przez firmy paczki deweloperskie.

6.2 Proces wykrywania twarzy


Uogólniony proces detekcji twarzy na obrazie został przedstawiony na grafie 6.2. Proces przetwarzania zadań detekcji rozpoczyna się od pobrania z bazy wszystkich zadań o statusie 'New'. Następnie każde zadanie przetwarzane jest osobno. Dla aktualnie procesowanego zadania pobierany jest obraz wejściowy z usługi Dropbox i zapisywany w lokalnym folderze. Następnym krokiem jest wywołanie procesu odpowiedzialnego za odpowiednie przygotowanie zdjęcia, a następnie pozyskanie oczekiwanych wyników, w sposób odpowiedni dla danego sposobu. Krok ten został szerzej opisany w podrozdziałach 6.2.1, 6.2.2 i 6.2.3. po uzyskaniu wyników każdą dostępną w programie metodą, zostaje utworzony obraz wyjściowy dla każdej metody (haar, azure, ..), które zostaje wgrany do odpowiedniego folderu w usłudze Dropbox. Po poprawnym wgraniu plików wynikowych informacja o rezultatach zostaje dodana do bazy danych. Po wykonaniu zadania bez żadnych błędów, request zostaje oznaczony jako zakończony, w innym przypadku zostaje nadany mu status 'Error'. Proces powtarzany jest dla każdego wpisu pozyskanego z bazy.



Rysunek 6.2: Proces wykrywania twarzy

6.2.1 Open Cv Haar


Pierwszą z metod detekcji twarzy, która została zintegrowana z programem jest detekcja metodą Haar’a. Algorytm został opisany w rozdziale 3.3.1. Przed uruchomieniem detekcji twarzy, obraz wejściowy należy odpowiednio przygotować. W tym celu wcześniej pobrany obraz zostaje wczytany do programu i przekonwertowany do odcieni szarości. Tak przygotowany obraz można poddać detekcji. Detektor zwraca współrzędne obszarów zawierających w sobie twarze. Tak uzyskane dane należy przekonwertować do formatu, który został przyjęty jako wspólny dla wszystkich metod.



Rysunek 6.3: Wykrywanie twarzy metodą Haar

6.2.2 Open Cv Dnn

Proces detekcji z wykorzystaniem głęboko uczonej sieci neuronowej nie wymaga formatowania obrazu do skali szarości, ale za to obraz musi zostać przeskalowany do odpowiedniego, wcześniej przyjętego rozmiaru. Dodatkową zaletą tej metody jest format odpowiedzi detektora, który oprócz obszaru zawierającego twarz zwraca również 'pewność' z jaką twarz została wykryta, co pozwala na odfiltrowanie niezadowalających użytkownika wyników.




Rysunek 6.4: Wykrywanie twarzy metodą DNN

6.2.3 Azure Cognitive Services


Kolejną wykorzystana metoda detekcji twarzy, korzysta z usługi dostępnej na platformie Azure, dzięki czemu środowisko rozruchowe zostaje odciążone z obliczeń związanych z przetwarzaniem obrazu. Proces wykrycia twarzy ogranicza się do przesłania wybranego obrazu do Cognitive Services Api. W odpowiedzi klient uzyskuje JSON zawierający parametry, które podano jako wy-

magane podczas wykonywania zapytania. JSON zostaje zparsowany na obiekt, którego wartości zostają przekonwertowane do wymaganego formatu [startX, startY, endX, endY].



Rysunek 6.5: Wykrywanie twarzy używając Azure Cognitive Services

6.3 Proces trenowania sieci neuronowych




Rysunek 6.6: Proces trenowania sieci

Proces trenowania sieci został przedstawiony na grafie 6.6. Proces zaczyna się od sprawdzenia jakie dane uczące (osoby utworzone w zakładce 'People' aplikacji webowej) są dostępne lokal-

nie. Repozytorium zostaje porównane z danymi dostępnymi w bazie, a następnie zostają pobrane zdjęcia wszystkich brakujących osób do lokalnej ścieżki. Kolejnym krokiem jest pobranie z bazy wszystkich nowych grup sieci neuronowych, które nie zostały jeszcze zakończone. Następnie dla każdego zgłoszenia z listy wykonywany jest proces przygotowania danych uczących na podstawie zdjęć osób, które wybrano podczas tworzenia sieci neuronowej w aplikacji webowej. Po odpowiednim przygotowaniu danych sieć zostaje nauczona i dla większości metod zostaje utworzony plik w formacie xml przechowujący wytrenowany model. Taki plik zostaje dodany do bazy oraz wysłany do odpowiedniego folderu w Dropboxie. W przypadku braku komplikacji, request zostaje oznaczony jako zakończony. Proces zostaje powtórzony dla każdego zadania wczytanego do listy na początku grafu. Sposób przygotowania danych oraz nauczania dla poszczególnych metod został opisany w kolejnych podrozdziałach.

6.3.1 Trenowanie identyfikatorów Open Cv

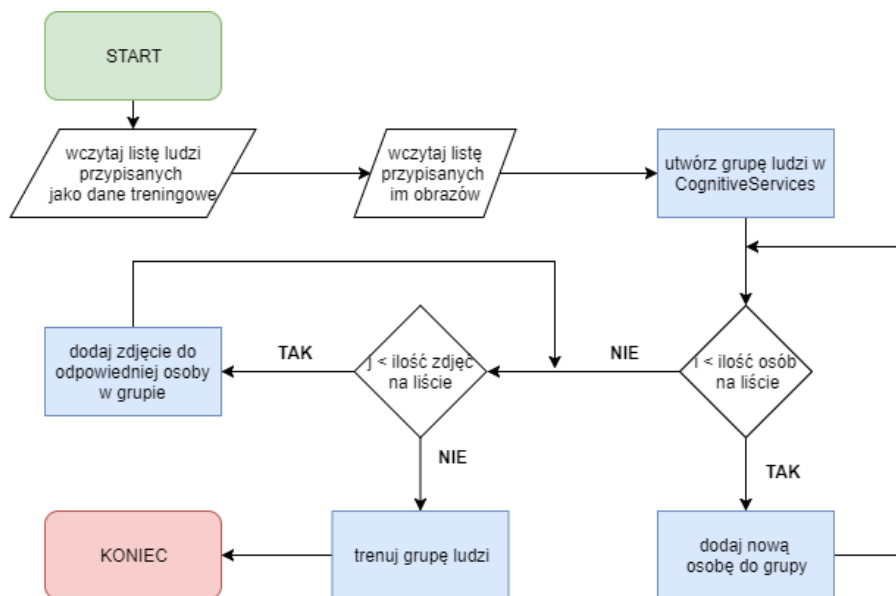


Rysunek 6.7: Trenowanie sieci neuronowej Open Cv

Ogólny schemat procesu trenowania identyfikatorów twarzy OpenCv (Eigenfaces, Fisherfaces, LHGP) został przedstawiony na rysunku 6.7. Proces rozpoczyna się od stworzenia listy zawierającej wszystkie przypisane do sieci osoby oraz załączone do nich obrazy. Następnie dla każdego zdjęcia z listy zostaje wykonany preprocessing. Pierwszym krokiem jest próba wykrycia twarzy na obrazie. W przypadku nie znalezienia twarzy, obraz zostaje zignorowany i program przechodzi do przetwarzania kolejnego obrazu. Jeśli na zdjęciu zostanie zlokalizowana twarz, to obszar ją zawierający zostaje przeskalowany do odcieni szarości, a następnie przekonwertowany do postaci

numpy array. Wektor zawierający informację o obrazie twarzy zostaje dodany do listy uczącej wraz z odpowiadającym mu ID osoby, od której pochodził obraz. Po przetworzeniu wszystkich obrazów na liście, zostaje utworzony jeden z trzech wcześniej wymienionych identyfikatorów twarzy. Ostatnim krokiem jest wywołanie funkcji uczącej.

6.3.2 Trenowanie identyfikatora Azure




Rysunek 6.8: Trenowanie usługi Azure Cognitive Services

Proces rozpoczyna się od wczytania wszystkich osób oraz ich zdjęć, które zostały przypisane do zadania trenowania sieci. Na diagramie 6.8 niebieskim kolorem oznaczono zapytania do Azure Cognitive Services Api. Pierwszym i najważniejszym krokiem jest utworzenie nowej AzureLargeGroup, do której w następnym kroku zostaną dodane id/nazwy wszystkich osób znajdujących się na wczytanej liście. Następnie każdy obraz z listy zostaje przypisany odpowiedniej osobie w AzureLargeGroup. W tym rozwiązaniu klient nie musi martwić się detekcją twarzy na obrazie, bo jest ona wykonywana przez usługę Azure po przesłaniu obrazu. W przypadku problemów z wykryciem twarzy na obrazie, zostanie zwrócona informacja mówiąca o tym że plik zostanie zignorowany podczas procesu nauczania. Po dodaniu wszystkich zdjęć, program wywołuje funkcję trenowania nowej sieci na podstawie danych dołączonych do AzureLargeGroup. Już po kilku sekundach, identyfikator tożsamości udostępniony przez usługę Azure jest gotowy do działania.

6.4 Proces rozpoznawania twarzy

Ogólny proces rozpoznawania twarzy przedstawiony na rysunku 6.9 jest podobny do wcześniej opisywanych procesów detekcji i trenowania. Proces rozpoczyna się od pobrania do lokalnej ścieżki wszystkich modeli sieci neuronowej, których aktualnie nie ma w katalogu. W kolejnym


etapie zostają wczytane wszystkie nowe zadania rozpoznania twarzy. Dla każdego z requestów na liście wykonywane są te same czynności, a pierwszą z nich jest pobranie pliku wejściowego z usługi Dropbox. Następnie twarz zostaje rozpoznana za pomocą każdego dostępnego algorytmu identyfikacji. Poszczególne metody zostały szerzej opisane w kolejnym podrozdziale. Po ukończeniu identyfikacji tożsamości, wszystkie uzyskane wyniki zostają wprowadzone do bazy danych, a zadanie oznaczone jako ukończone. Gdy zadania na liście skończą się to dochodzi do zakończenia procesu.



Rysunek 6.9: Proces identyfikacji tożsamości

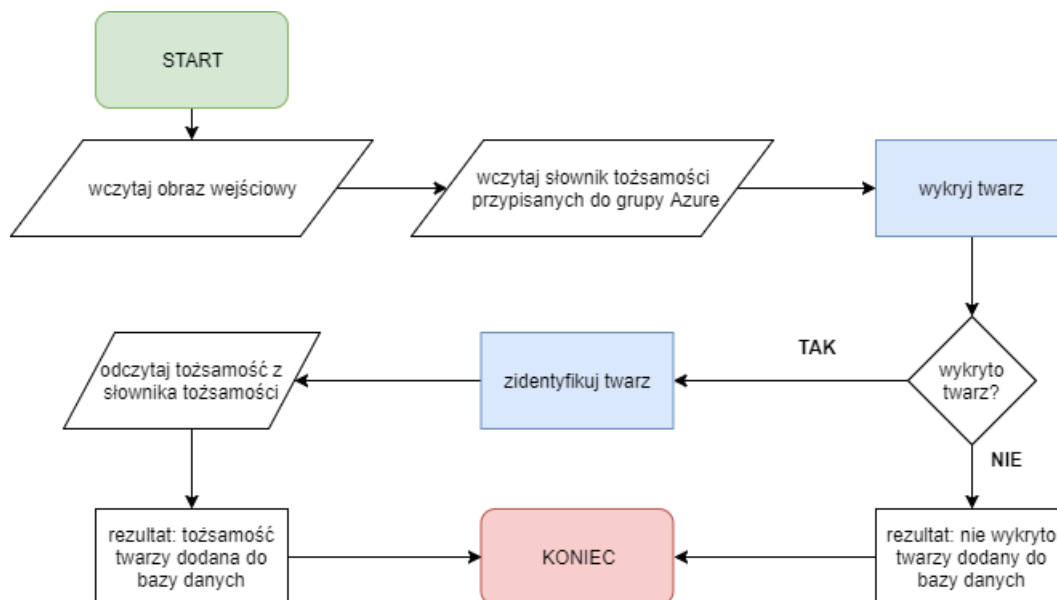
6.4.1 OpenCv

Niezależnie od typu FaceRecognizera, proces rozpoznawania twarzy z użyciem algorytmów OpenCv wygląda identycznie. Obraz zostaje wczytany do programu, a następnie wykonuje się program wykrywający twarz. W przypadku nie wykrycia żadnej twarzy, proces zostaje zakończony. Jeśli twarz zostanie wykryta to program wczytuje z odpowiedniego pliku wytrenowany model FaceRecognizera. Obraz z twarzą zostaje przekonwertowany do numpy array, które podaje się jako wejście do metody rozpoznającej. Rezultat z numerem Id rozpoznanej osoby zostaje dodany do bazy danych.



Rysunek 6.10: Proces identyfikacji osoby wykorzystując Open Cv

6.4.2 Azure Cognitive Services



Rysunek 6.11: Proces identyfikacji osoby wykorzystując Azure Cognitive Services

Proces detekcji twarzy przy pomocy Azure Cognitive Services jest mniej obciążający dla platformy, na której uruchomiono program, ale za to wymaga równie wielu kroków. Pierwszym z nich jest wczytanie słownika tożsamości przypisanych do AzureLargeGroup. W kolejnym etapie zdjęcie wejściowe zostaje wysłane do usługi detekcji opisanej w 6.2.3 ale ze zmodyfikowanymi

parametrami. W tym przypadku, każdej wykrytej twarzy zostaje nadany numer identyfikacyjny Azure. Jeśli jakaś twarz została znaleziona to kolejnym etapem jest wysłanie żądania identyfikacji uzyskanej twarzy przy pomocy AzureLargeGroup, która została przypisana do tego requesta. Tożsamość rozpoznana przez CS zostaje zwrócona w postaci numeru identyfikacyjnego usługi, dlatego musi ona zostać porównana z wcześniej wczytanym słownikiem, który pozwala na odczytanie Id osoby istniejącej w bazie danych programu.

Rozdział 7

Ocena skuteczności działania ... (wybranych metod) **TODO**

7.1 Wykrywanie twarzy - różne przykłady

7.2 Trenowanie- czas trwania itd

7.3 Rozpoznawanie- skuteczność, porównanie wyników

7.4 Ocena przydatności wybranych usług itd w IoT

Rozdział 8

Podsumowanie

Bibliografia

- [1] *angular-chart.js - beautiful, reactive, responsive charts for Angular.JS using Chart.js*. URL: <https://jtblin.github.io/angular-chart.js/> (term. wiz. 21.01.2017).
- [2] *LaTeX - A document preparation system*. URL: <https://www.latex-project.org/> (term. wiz. 21.01.2017).
- [3] *Zotero | Home*. URL: <https://www.zotero.org/> (term. wiz. 21.01.2017).

Dodatki

Dodatek do niniejszej pracy stanowi płyta CD zawierająca:

- pracę dyplomową w postaci źródłowej (LaTeX),
- pracę dyplomową w postaci pliku pdf.

Spis rysunków

3.1	Schemat klasycznego wzorca MVC	8
3.2	Obliczenia chmurowe	9
3.3	Raspberry Pi 3 B	10
3.4	Czujnik DHT11	11
3.5	Raspberry Pi Camera Hd	11
3.6	Szablony cech Haar’a	12
3.7	Budowa głębokiej sieci neuronowej	13
4.1	Budowa systemu zarządzania domem	15
5.1	Wygląd strony głównej	17
5.2	Strona główna widoku utworzonym w Angular 4	19
5.3	Widok detekcji twarzy	19
5.4	Tworzenie nowej detekcji	20
5.5	Widok zakończonej detekcji	20
5.6	Lista utworzonych ludzi	21
5.7	Widok osoby	21
5.8	Strona przedstawiająca istniejące grupy usług rozpoznawania tożsamości	22
5.9	Tworzenie nowej grupy sieci neuronowych	22
5.10	Szczegółowe informacje o grupie sieci neuronowych	23
5.11	Lista zadań identyfikacji osoby	23
5.12	Formularz tworzenia zadania identyfikacji	24
5.13	Zakończony request identyfikacji	24
6.1	Proces działania aplikacji konsolowej	25
6.2	Proces wykrywania twarzy	26
6.3	Wykrywanie twarzy metodą Haar	27
6.4	Wykrywanie twarzy metodą DNN	27
6.5	Wykrywanie twarzy używając Azure Cognitive Services	28
6.6	Proces trenowania sieci	28
6.7	Trenowanie sieci neuronowej Open Cv	29

6.8	Trenowanie usługi Azure Cognitive Services	30
6.9	Proces identyfikacji tożsamości	31
6.10	Proces identyfikacji osoby wykorzystując Open Cv	32
6.11	Proces identyfikacji osoby wykorzystując Azure Cognitive Servces	32

Spis tablic

3.1 Parametry czujnika	11
----------------------------------	----